

# Введение в искусственный интеллект. Современное компьютерное зрение

Тема семинара: Генеративные состязательные сети

Бабин Д.Н., Иванов И.Е., Петюшко А.А.

кафедра Математической Теории Интеллектуальных Систем



## 1 Вывод формул!



- 1 Вывод формул!
- 2 Условные состязательные генеративные сети

- 1 Вывод формул!
- 2 Условные состязательные генеративные сети
- 3 Вариационный автоэнкодер

# Энтропия для унитарного кодирования

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ .



# Энтропия для унитарного кодирования

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ .
- Энтропия  $H(p) = -\sum_{i=1}^n p_i \log p_i$



# Энтропия для унитарного кодирования

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ .
- Энтропия  $H(p) = -\sum_{i=1}^n p_i \log p_i$
- Унитарное кодирование для класса  $y_c$ :  
 $y_{one-hot} = (0, \dots, 1, \dots, 0), \quad y_i = 0, i \neq y_c, \quad y_i = 1, i = y_c$



# Энтропия для унитарного кодирования

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ .
- Энтропия  $H(p) = -\sum_{i=1}^n p_i \log p_i$
- Унитарное кодирование для класса  $y_c$ :  
 $y_{one-hot} = (0, \dots, 1, \dots, 0), \quad y_i = 0, i \neq y_c, \quad y_i = 1, i = y_c$
- В этом случае для  $i = y_c$ :  $p_i \log p_i = 1 \cdot \log 1 = 1 \cdot 0 = 0$





# Энтропия для унитарного кодирования

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ .
- Энтропия  $H(p) = -\sum_{i=1}^n p_i \log p_i$
- Унитарное кодирование для класса  $y_c$ :  
 $y_{one-hot} = (0, \dots, 1, \dots, 0), \quad y_i = 0, i \neq y_c, \quad y_i = 1, i = y_c$
- В этом случае для  $i = y_c$ :  $p_i \log p_i = 1 \cdot \log 1 = 1 \cdot 0 = 0$
- А для  $i \neq y_c$  воспользуемся правилом Лопиталя:  $p_i \log p_i = \lim_{x \rightarrow 0} x \log x = \lim_{x \rightarrow 0} \frac{\log x}{1/x} = \lim_{x \rightarrow 0} \frac{(\log x)'}{(1/x)'} = \lim_{x \rightarrow 0} \frac{1/x}{-1/x^2} = -\lim_{x \rightarrow 0} x = 0$



# Энтропия для унитарного кодирования

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ .
- Энтропия  $H(p) = -\sum_{i=1}^n p_i \log p_i$
- Унитарное кодирование для класса  $y_c$ :  
 $y_{one-hot} = (0, \dots, 1, \dots, 0), \quad y_i = 0, i \neq y_c, \quad y_i = 1, i = y_c$
- В этом случае для  $i = y_c$ :  $p_i \log p_i = 1 \cdot \log 1 = 1 \cdot 0 = 0$
- А для  $i \neq y_c$  воспользуемся правилом Лопиталья:  $p_i \log p_i = \lim_{x \rightarrow 0} x \log x = \lim_{x \rightarrow 0} \frac{\log x}{1/x} = \lim_{x \rightarrow 0} \frac{(\log x)'}{(1/x)'} = \lim_{x \rightarrow 0} \frac{1/x}{-1/x^2} = -\lim_{x \rightarrow 0} x = 0$
- Таким образом, разобрали все случаи, и  $H(p) = -\sum_{i=1}^n p_i \log p_i = 0$ .



# Неравенство Гиббса (1)

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ ,



# Неравенство Гиббса (1)

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ ,
- $q = (q_1, \dots, q_n)$ ,  $\sum_{i=1}^n q_i = 1, 0 \leq q_i \leq 1$ .



# Неравенство Гиббса (1)

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ ,
- $q = (q_1, \dots, q_n)$ ,  $\sum_{i=1}^n q_i = 1, 0 \leq q_i \leq 1$ .

## Неравенство Гиббса

$\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$  для любых распределений  $p, q$ , при этом равенство достигается только при  $p = q$ .

### Доказательство.

- При  $x > 0$  имеем  $\log x \leq x - 1$ , причем равенство достигается только при  $x = 1$ .



# Неравенство Гиббса (1)

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ ,
- $q = (q_1, \dots, q_n)$ ,  $\sum_{i=1}^n q_i = 1, 0 \leq q_i \leq 1$ .

## Неравенство Гиббса

$\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$  для любых распределений  $p, q$ , при этом равенство достигается только при  $p = q$ .

### Доказательство.

- При  $x > 0$  имеем  $\log x \leq x - 1$ , причем равенство достигается только при  $x = 1$ .
- Пусть  $I$  — множество индексов, в которых  $p_i > 0$ .



# Неравенство Гиббса (1)

- Пусть  $p = (p_1, \dots, p_n)$ ,  $\sum_{i=1}^n p_i = 1, 0 \leq p_i \leq 1$ ,
- $q = (q_1, \dots, q_n)$ ,  $\sum_{i=1}^n q_i = 1, 0 \leq q_i \leq 1$ .

## Неравенство Гиббса

$\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$  для любых распределений  $p, q$ , при этом равенство достигается только при  $p = q$ .

### Доказательство.

- При  $x > 0$  имеем  $\log x \leq x - 1$ , причем равенство достигается только при  $x = 1$ .
- Пусть  $I$  — множество индексов, в которых  $p_i > 0$ .
- Тогда  $\sum_{i \in I} p_i \log q_i - \sum_{i \in I} p_i \log p_i = \sum_{i \in I} p_i \log \frac{q_i}{p_i} \leq \sum_{i \in I} p_i (\frac{q_i}{p_i} - 1) = \sum_{i \in I} q_i - \sum_{i \in I} p_i \leq 1 - \sum_{i \in I} p_i = 1 - 1 = 0$



## Доказательство.

- В случае  $p_i = 0$ :
  - $p_i \log p_i = 0$  (см. ранее),





## Доказательство.

- В случае  $p_i = 0$ :
  - $p_i \log p_i = 0$  (см. ранее),
  - Тогда  $\sum_{i:p_i=0} p_i \log q_i - \sum_{i:p_i=0} p_i \log p_i = \sum_{i:p_i=0} p_i \log q_i \leq \sum_{i:p_i=0} p_i \log 1 = 0$ .



## Доказательство.

- В случае  $p_i = 0$ :
  - $p_i \log p_i = 0$  (см. ранее),
  - Тогда  $\sum_{i:p_i=0} p_i \log q_i - \sum_{i:p_i=0} p_i \log p_i = \sum_{i:p_i=0} p_i \log q_i \leq \sum_{i:p_i=0} p_i \log 1 = 0$ .
- Таким образом,  $\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$ , при этом равенство возможно только при  $\frac{q_i}{p_i} = 1$  в случае  $i \in I$ ,



## Доказательство.

- В случае  $p_i = 0$ :
  - $p_i \log p_i = 0$  (см. ранее),
  - Тогда  $\sum_{i:p_i=0} p_i \log q_i - \sum_{i:p_i=0} p_i \log p_i = \sum_{i:p_i=0} p_i \log q_i \leq \sum_{i:p_i=0} p_i \log 1 = 0$ .
- Таким образом,  $\sum_{i=1}^n p_i \log p_i \geq \sum_{i=1}^n p_i \log q_i$ , при этом равенство возможно только при  $\frac{q_i}{p_i} = 1$  в случае  $i \in I$ ,
- Но тогда и  $p_i = q_i = 0$ ,  $i \notin I$ . ■



## Определение

Функция близости (divergence) двух распределений, заданных на одном пространстве функций распределения  $S$  — это функция  $D(\cdot||\cdot) : S \times S \rightarrow \mathbb{R}$ , такая что:

- 1  $D(P||Q) \geq 0$  для всех  $P, Q \in S$
- 2  $D(P||Q) = 0 \Leftrightarrow P = Q$



# Функция близости Кульбака-Лейблера

## Определение

Функция близости (divergence) двух распределений, заданных на одном пространстве функций распределения  $S$  — это функция  $D(\cdot||\cdot) : S \times S \rightarrow \mathbb{R}$ , такая что:

- 1  $D(P||Q) \geq 0$  для всех  $P, Q \in S$
- 2  $D(P||Q) = 0 \Leftrightarrow P = Q$

## Функция близости Кульбака-Лейблера

$$D_{KL}(P||Q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$



# Функция близости Кульбака-Лейблера

## Определение

Функция близости (divergence) двух распределений, заданных на одном пространстве функций распределения  $S$  — это функция  $D(\cdot||\cdot) : S \times S \rightarrow \mathbb{R}$ , такая что:

- 1  $D(P||Q) \geq 0$  для всех  $P, Q \in S$
- 2  $D(P||Q) = 0 \Leftrightarrow P = Q$

## Функция близости Кульбака-Лейблера

$$D_{KL}(P||Q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

**Доказательство.**  $D_{KL}(P||Q) = \sum_x p(x) \log \frac{p(x)}{q(x)} = \sum_x p(x) \log p(x) - \sum_x p(x) \log q(x) \geq 0$ ,  
при этом равенство достигается только при  $P = Q$  (следствие из неравенства Гиббса). ■



# Метрика на основе функции близости Йенсена-Шеннона (1)

## Функция близости Йенсена-Шеннона

$$D_{JS}(P||Q) = \frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M), \text{ где } M = \frac{1}{2}(P + Q).$$



# Метрика на основе функции близости Йенсена-Шеннона (1)

## Функция близости Йенсена-Шеннона

$$D_{JS}(P||Q) = \frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M), \text{ где } M = \frac{1}{2}(P + Q).$$

## Определение метрики

Функция  $d : X \times X \rightarrow \mathbb{R}$  называется метрикой на пространстве  $X$ , если:

- ❶  $d(x, y) = 0 \Leftrightarrow x = y$ ,
- ❷  $d(x, y) = d(y, x)$ ,
- ❸  $d(x, z) \leq d(x, y) + d(y, z)$ .





# Метрика на основе функции близости Йенсена-Шеннона (1)

## Функция близости Йенсена-Шеннона

$$D_{JS}(P||Q) = \frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M), \text{ где } M = \frac{1}{2}(P + Q).$$

## Определение метрики

Функция  $d : X \times X \rightarrow \mathbb{R}$  называется метрикой на пространстве  $X$ , если:

- 1  $d(x, y) = 0 \Leftrightarrow x = y$ ,
- 2  $d(x, y) = d(y, x)$ ,
- 3  $d(x, z) \leq d(x, y) + d(y, z)$ .

## Теорема

$\sqrt{D_{JS}(P||Q)}$  — метрика.

# Метрика на основе функции близости Йенсена-Шеннона (2)

**Доказательство.**

①  $\sqrt{D_{JS}(P||Q)} = 0 \Leftrightarrow D_{JS}(P||Q) = 0 \Leftrightarrow D_{KL}(P||M) = D_{KL}(Q||M) = 0, P = Q = \frac{1}{2}(P + Q)$  (из свойств функции близости  $D_{KL}$ );

---

<sup>1</sup>Endres D. M., Schindelin J. E. "A new metric for probability distributions". 2003.

## Метрика на основе функции близости Йенсена-Шеннона (2)

### Доказательство.

- 1  $\sqrt{D_{JS}(P||Q)} = 0 \Leftrightarrow D_{JS}(P||Q) = 0 \Leftrightarrow D_{KL}(P||M) = D_{KL}(Q||M) = 0, P = Q = \frac{1}{2}(P + Q)$  (из свойств функции близости  $D_{KL}$ );
- 2  $\sqrt{D_{JS}(P||Q)} = \sqrt{\frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M)} = \sqrt{\frac{1}{2}D_{KL}(Q||M) + \frac{1}{2}D_{KL}(P||M)} = \sqrt{D_{JS}(Q||P)}$ ;

<sup>1</sup>Endres D. M., Schindelin J. E. "A new metric for probability distributions". 2003.

## Метрика на основе функции близости Йенсена-Шеннона (2)

### Доказательство.

- ❶  $\sqrt{D_{JS}(P||Q)} = 0 \Leftrightarrow D_{JS}(P||Q) = 0 \Leftrightarrow D_{KL}(P||M) = D_{KL}(Q||M) = 0, P = Q = \frac{1}{2}(P + Q)$  (из свойств функции близости  $D_{KL}$ );
- ❷  $\sqrt{D_{JS}(P||Q)} = \sqrt{\frac{1}{2}D_{KL}(P||M) + \frac{1}{2}D_{KL}(Q||M)} = \sqrt{\frac{1}{2}D_{KL}(Q||M) + \frac{1}{2}D_{KL}(P||M)} = \sqrt{D_{JS}(Q||P)}$ ;
- ❸ А с неравенством треугольника здесь все действительно сложнее. За деталями — см. дополнительную литературу<sup>1</sup>. ■

<sup>1</sup>Endres D. M., Schindelin J. E. "A new metric for probability distributions". 2003.

# GAN и оптимальное распределение D/G (1)

Если обозначить за  $p_g$  — распределение  $G(z)$ , то оригинальную функцию потерь

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z)))]$$

можно переписать как



# GAN и оптимальное распределение D/G (1)

Если обозначить за  $p_g$  — распределение  $G(z)$ , то оригинальную функцию потерь

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z)))]$$

можно переписать как

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{x \sim p_g} \log(1 - D(x))]$$



# GAN и оптимальное распределение D/G (1)

Если обозначить за  $p_g$  — распределение  $G(z)$ , то оригинальную функцию потерь

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z)))]$$

можно переписать как

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{x \sim p_g} \log(1 - D(x))]$$

## Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$



# GAN и оптимальное распределение D/G (1)

Если обозначить за  $p_g$  — распределение  $G(z)$ , то оригинальную функцию потерь

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{z \sim p_z} \log(1 - D(G(z)))]$$

можно переписать как

$$\min_G \max_D V(D, G) = \min_G \max_D [\mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{x \sim p_g} \log(1 - D(x))]$$

## Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$

**Доказательство.**  $V(D, G) = \mathbb{E}_{x \sim p_{data}} \log D(x) + \mathbb{E}_{x \sim p_g} \log(1 - D(x)) =$   
 $\int_x (p_{data}(x) \log D(x) + p_g(x) \log(1 - D(x))) dx$





## Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$

**Доказательство.** Найдем точку экстремума функции  $f(s) = p_{data} \log s + p_g \log(1 - s)$ :



## Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$

**Доказательство.** Найдем точку экстремума функции  $f(s) = p_{data} \log s + p_g \log(1 - s)$ :

- $f'(s) = \frac{p_{data}}{s} - \frac{p_g}{1-s},$
- $f'(s) = 0 \Leftrightarrow p_{data}(1 - s) - p_g s = 0 \Leftrightarrow s = \frac{p_{data}}{p_{data} + p_g}.$



## Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$

**Доказательство.** Найдем точку экстремума функции  $f(s) = p_{data} \log s + p_g \log(1 - s)$ :

- $f'(s) = \frac{p_{data}}{s} - \frac{p_g}{1-s},$
- $f'(s) = 0 \Leftrightarrow p_{data}(1 - s) - p_g s = 0 \Leftrightarrow s = \frac{p_{data}}{p_{data} + p_g}.$

При этом  $s = \frac{p_{data}}{p_{data} + p_g}$  — точка максимума функции  $f(s)$  (можно проверить, например, что  $\lim_{s \rightarrow 0+} f'(s) > 0, \lim_{s \rightarrow 1-} f'(s) < 0$ ).



## Теорема

$$\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}.$$

**Доказательство.** Найдем точку экстремума функции  $f(s) = p_{data} \log s + p_g \log(1 - s)$ :

- $f'(s) = \frac{p_{data}}{s} - \frac{p_g}{1-s},$
- $f'(s) = 0 \Leftrightarrow p_{data}(1 - s) - p_g s = 0 \Leftrightarrow s = \frac{p_{data}}{p_{data} + p_g}.$

При этом  $s = \frac{p_{data}}{p_{data} + p_g}$  — точка максимума функции  $f(s)$  (можно проверить, например, что  $\lim_{s \rightarrow 0+} f'(s) > 0, \lim_{s \rightarrow 1-} f'(s) < 0$ ).

Таким образом,  $\arg \max_D V(D, G) = D_G = \frac{p_{data}}{p_{data} + p_g}. \blacksquare$



# GAN и оптимальное распределение D/G (3)

Пусть  $C(G) = \max_D V(D, G)$

Теорема

$$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$$



# GAN и оптимальное распределение D/G (3)

Пусть  $C(G) = \max_D V(D, G)$

## Теорема

$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$

**Доказательство.**

- $$C(G) = \mathbb{E}_{x \sim p_{data}} \log D_G(x) + \mathbb{E}_{x \sim p_g} \log(1 - D_G(x)) =$$
$$\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} + \mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)},$$



# GAN и оптимальное распределение D/G (3)

Пусть  $C(G) = \max_D V(D, G)$

## Теорема

$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$

Доказательство.

- $C(G) = \mathbb{E}_{x \sim p_{data}} \log D_G(x) + \mathbb{E}_{x \sim p_g} \log(1 - D_G(x)) =$   
 $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} + \mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)},$
- $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} = \mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{\frac{p_{data}(x) + p_g(x)}{2}} - \mathbb{E}_{x \sim p_{data}} \log 2 =$   
 $D_{KL}(p_{data} || \frac{p_{data}(x) + p_g(x)}{2}) - \log 2,$



# GAN и оптимальное распределение D/G (3)

Пусть  $C(G) = \max_D V(D, G)$

## Теорема

$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$

Доказательство.

- $C(G) = \mathbb{E}_{x \sim p_{data}} \log D_G(x) + \mathbb{E}_{x \sim p_g} \log(1 - D_G(x)) =$   
 $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} + \mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)},$
- $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} = \mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{\frac{p_{data}(x) + p_g(x)}{2}} - \mathbb{E}_{x \sim p_{data}} \log 2 =$   
 $D_{KL}(p_{data} || \frac{p_{data}(x) + p_g(x)}{2}) - \log 2,$
- $\mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)} = D_{KL}(p_g || \frac{p_{data}(x) + p_g(x)}{2}) - \log 2,$





# GAN и оптимальное распределение D/G (3)

Пусть  $C(G) = \max_D V(D, G)$

## Теорема

$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$

Доказательство.

- $C(G) = \mathbb{E}_{x \sim p_{data}} \log D_G(x) + \mathbb{E}_{x \sim p_g} \log(1 - D_G(x)) =$   
 $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} + \mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)},$
- $\mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} = \mathbb{E}_{x \sim p_{data}} \log \frac{p_{data}(x)}{\frac{p_{data}(x) + p_g(x)}{2}} - \mathbb{E}_{x \sim p_{data}} \log 2 =$   
 $D_{KL}(p_{data} \parallel \frac{p_{data}(x) + p_g(x)}{2}) - \log 2,$
- $\mathbb{E}_{x \sim p_g} \log \frac{p_g(x)}{p_{data}(x) + p_g(x)} = D_{KL}(p_g \parallel \frac{p_{data}(x) + p_g(x)}{2}) - \log 2,$
- $\Rightarrow C(G) = D_{KL}(p_{data} \parallel \frac{p_{data}(x) + p_g(x)}{2}) + D_{KL}(p_g \parallel \frac{p_{data}(x) + p_g(x)}{2}) - 2 \log 2,$



## Теорема

$$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$$

**Доказательство.**

- $\Rightarrow C(G) = 2D_{JS}(p_{data}||p_g) - \log 4 \geq -\log 4,$



## Теорема

$$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$$

## Доказательство.

- $\Rightarrow C(G) = 2D_{JS}(p_{data}||p_g) - \log 4 \geq -\log 4,$
- При этом  $C(G) = -\log 4 \Leftrightarrow D_{JS}(p_{data}||p_g) = 0 \Leftrightarrow p_{data} = p_g. \blacksquare$



## Теорема

$$\arg \min_G C(G) = p_{data}, C(p_{data}) = -\log 4.$$

## Доказательство.

- $\Rightarrow C(G) = 2D_{JS}(p_{data}||p_g) - \log 4 \geq -\log 4,$
- При этом  $C(G) = -\log 4 \Leftrightarrow D_{JS}(p_{data}||p_g) = 0 \Leftrightarrow p_{data} = p_g. \blacksquare$

**Замечание.** Таким образом, генератор  $G$  будет пытаться полностью повторять распределение исходных данных:  $p_g = p_{data}$ .

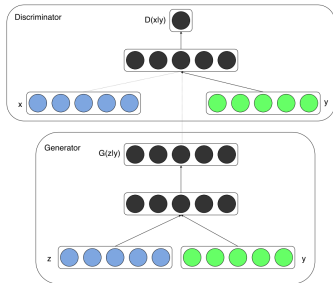


$$\min_G \max_D [\mathbb{E}_{x \sim p_{data}, y \sim p_y} \log D(x, y) + \mathbb{E}_{z \sim p_z, y \sim p_y} \log(1 - D(G(z, y), y))]$$




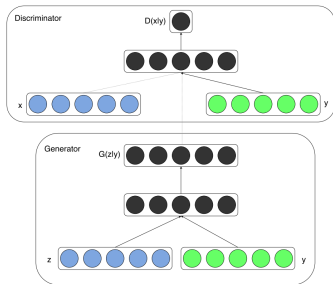
# Условные состязательные генеративные сети

$$\min_G \max_D [\mathbb{E}_{x \sim p_{data}, y \sim p_y} \log D(x, y) + \mathbb{E}_{z \sim p_z, y \sim p_y} \log(1 - D(G(z, y), y))]$$




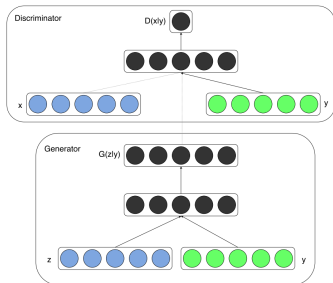
# Условные состязательные генеративные сети

$$\min_G \max_D [\mathbb{E}_{x \sim p_{data}, y \sim p_y} \log D(x, y) + \mathbb{E}_{z \sim p_z, y \sim p_y} \log(1 - D(G(z, y), y))]$$



# Условные состязательные генеративные сети

$$\min_G \max_D [\mathbb{E}_{x \sim p_{data}, y \sim p_y} \log D(x, y) + \mathbb{E}_{z \sim p_z, y \sim p_y} \log(1 - D(G(z, y), y))]$$




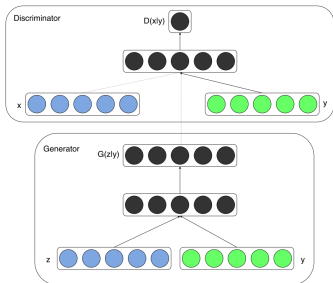
Ссылки для любознательных:

- 1 Image2Image Translation от Д. Михайлова



# Условные состязательные генеративные сети

$$\min_G \max_D [\mathbb{E}_{x \sim p_{data}, y \sim p_y} \log D(x, y) + \mathbb{E}_{z \sim p_z, y \sim p_y} \log(1 - D(G(z, y), y))]$$



Ссылки для любознательных:

- 1 Image2Image Translation от Д. Михайлова
- 2 Image Generation от А. Иванюты

## Вариационный автоэнкодер

Сначала реальные данные отображаются в простое распределение (например,  $z \sim N(\mu, \sigma^2)$ ) с помощью энкодера  $Enc$ , после чего отображаются обратно с помощью декодера  $Dec$ .  $Dec$  и  $Enc$  — нейросети, обучающиеся совместно. При генерации порождается  $z \sim N(\mu, \sigma^2)$  и используется только  $Dec(z)$ .

<sup>2</sup>Kingma, Diederik P., and Max Welling. "Auto-encoding variational bayes." 2013.

## Вариационный автоэнкодер

Сначала реальные данные отображаются в простое распределение (например,  $z \sim N(\mu, \sigma^2)$ ) с помощью энкодера  $Enc$ , после чего отображаются обратно с помощью декодера  $Dec$ .  $Dec$  и  $Enc$  — нейросети, обучающиеся совместно. При генерации порождается  $z \sim N(\mu, \sigma^2)$  и используется только  $Dec(z)$ .

### Замечания<sup>2</sup>:

- Если просто генерировать случайное  $z \sim N(\mu, \sigma^2)$ , то не сможем обучать сеть (нет возможности провести обратное распространение ошибки!)

<sup>2</sup>Kingma, Diederik P., and Max Welling. "Auto-encoding variational bayes." 2013.

## Вариационный автоэнкодер

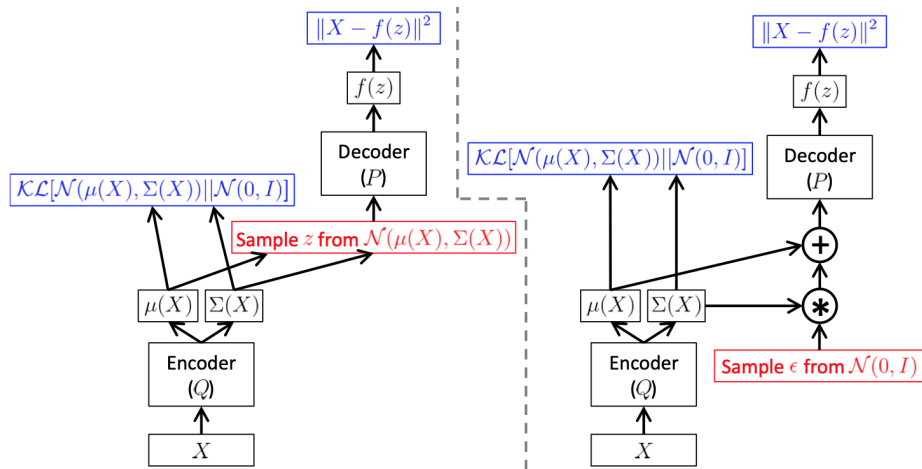
Сначала реальные данные отображаются в простое распределение (например,  $z \sim N(\mu, \sigma^2)$ ) с помощью энкодера  $Enc$ , после чего отображаются обратно с помощью декодера  $Dec$ .  $Dec$  и  $Enc$  — нейросети, обучающиеся совместно. При генерации порождается  $z \sim N(\mu, \sigma^2)$  и используется только  $Dec(z)$ .

### Замечания<sup>2</sup>:

- Если просто генерировать случайное  $z \sim N(\mu, \sigma^2)$ , то не сможем обучать сеть (нет возможности провести обратное распространение ошибки!)
- Применяется так называемый репараметризационный трюк (reparametrization trick): генерируется случайное значение  $z \sim N(0, 1)$ , после чего линейно домножается на  $\sigma$  и прибавляется  $\mu \Rightarrow$  можно пропускать градиенты по  $\sigma$  и  $\mu$ !

<sup>2</sup>Kingma, Diederik P., and Max Welling. "Auto-encoding variational bayes." 2013.

# Вариационный автоэнкодер — схема



Замечание: красным обозначены места без **backprop**, синим — функции потерь.



Спасибо за внимание!